¿Qué es Big Data?

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de
Big_Data

Curso Especialización
Inteligencia_Artificial y
Big_Data

Sistemas Big Data

¿Qué es BD?

Definición 3Vs

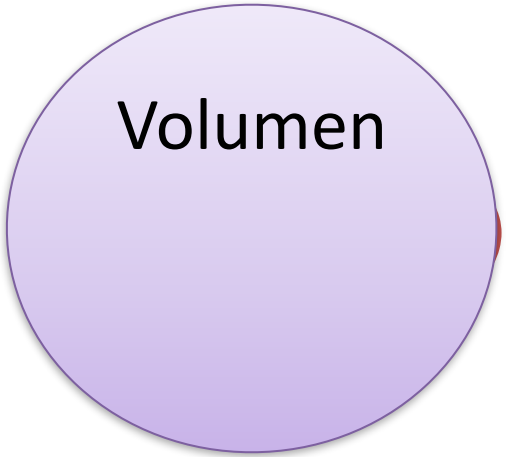

Sistemas Big Data

Volumen

BD

UNIDADES		ESCALA
Gigabytes	10^{9} bytes	
Terabytes	10^{12} bytes	PYME
Petabytes	10^{15} bytes	**100 PB** 2012
Exabytes	10^{18} bytes	
Zettabytes	10^{21} bytes	**44 ZB** 2020
Yotttabytes	10^{24} bytes	
Universo	$4*10^{79}$ átomos H	

Sistemas Big Data

¿Qué es BD?

Definición 3Vs

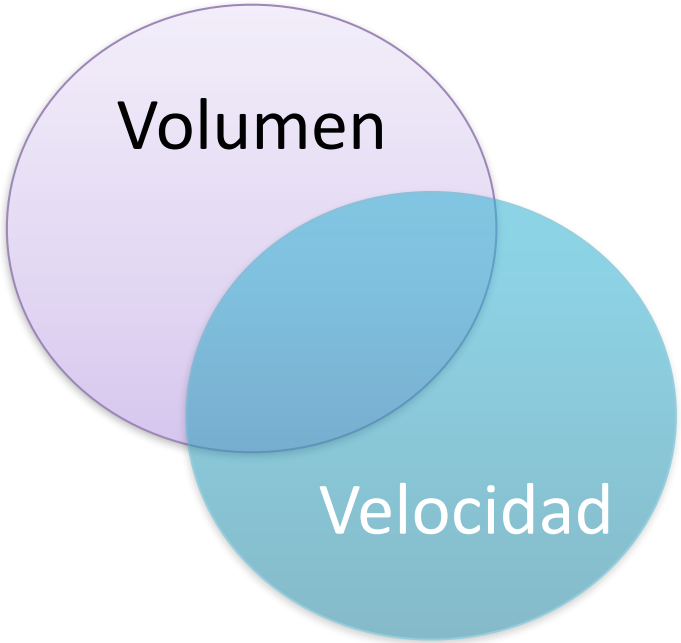

Sistemas Big Data

Velocidad

900 millones fotos/día

Ventana Temporal

Sistemas Big Data

¿Qué es BD?

Definición 3Vs

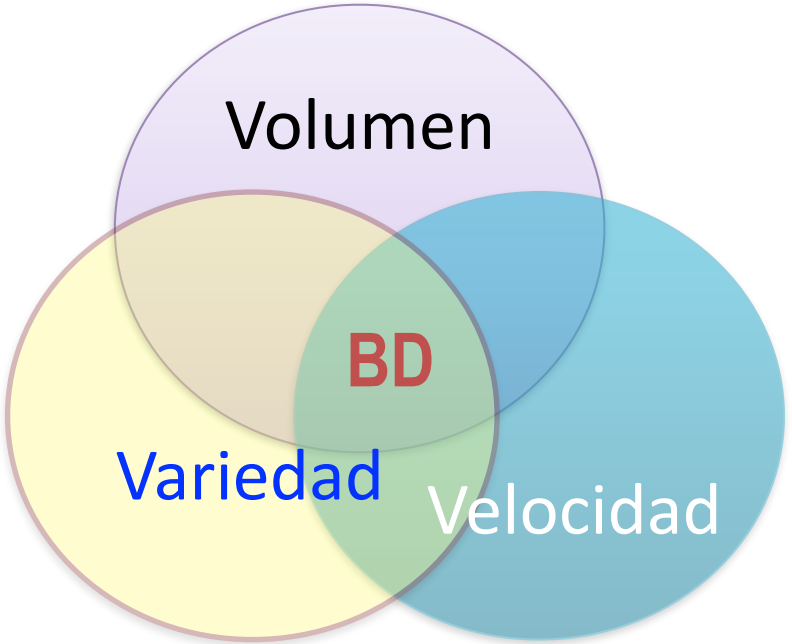

Sistemas Big Data

Variedad

- Ficheros XML
- Ficheros log
- Bases de datos
- Imágenes
- Audios
- Videos
- Webs
- Textos

Sistemas Big Data

Variedad

Hola Mundo + 4

Sistemas Big Data

Modelo de negocio BD

- **Usuarios** de datos
- **Proveedores** de datos
- **Facilitadores** de sistemas BD

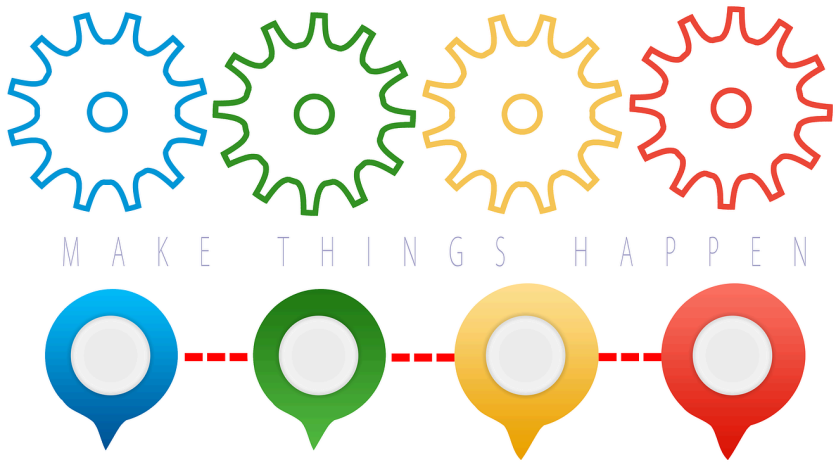

Sistemas Big Data

MNBD: Usuarios de datos

- **Toma de decisiones** estratégicas
- **Mejorar** los procesos internos
- **Enriquecer** productos, servicios y experiencia de clientes
- Desarrollo de **nuevos** productos y servicios

Sistemas Big Data

MNBD: Proveedores de datos

- **Recopilando** datos primarios y vendiéndolos a terceros
- **Agregando** datos y **empaquetando** datos internos para la venta

Sistemas Big Data

MNBD: Facilitadores

- Ofreciendo la **infraestructura**
- **Consultoría**
- Subcontratación de **técnicas analíticas**

¿Qué es Big Data?

- Definición 3Vs
- Modelos Negocio BD

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de
Big_Data

Curso Especialización
Inteligencia_Artificial y
Big_Data

Complejidad computacional

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de Big_Data

Curso Especialización Inteligencia_Artificial y Big_Data

Complejidad computacional

Duplicación digital

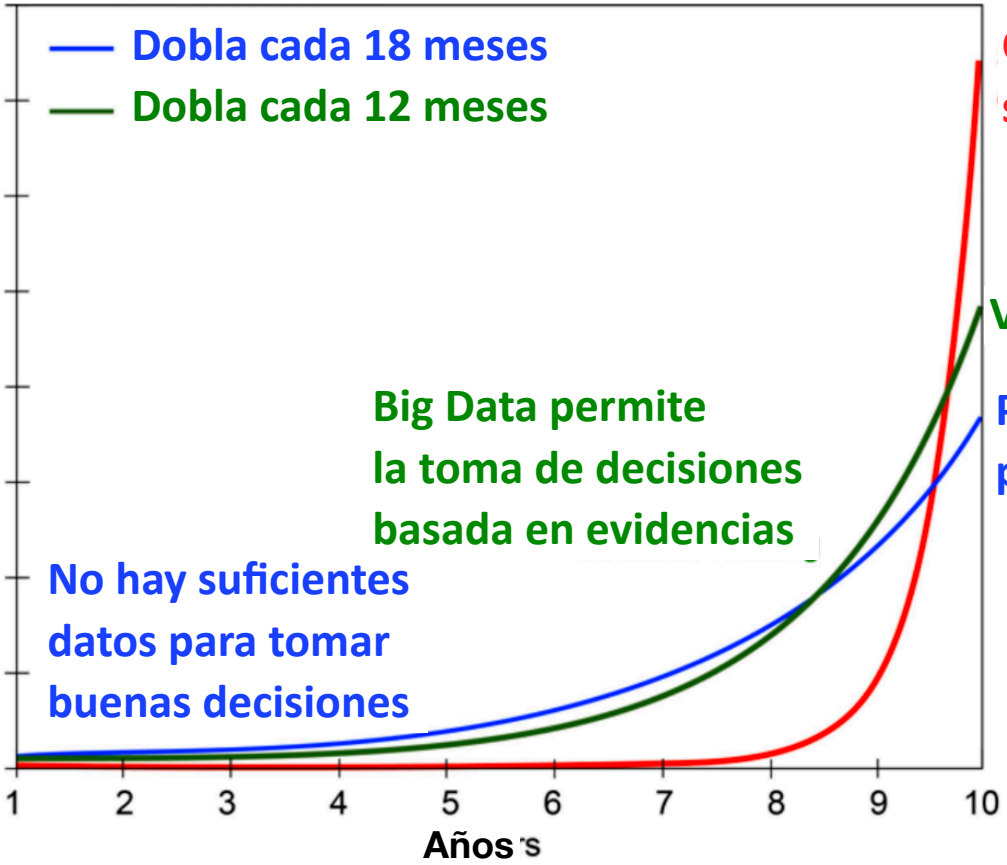

Complejidad computacional

Tiempo de ejecución

Ordenación de un vector

(método burbuja)

32	3	17	…	

n tamaño del vector

$f_{\mathscr{A}}(n)$ número de operaciones de $\mathscr{A}$

$$f_{\mathscr{A}}(n) \leq an^2 + bn + c$$

$$\mathscr{A} \equiv O(n^2)$$

Complejidad computacional

Crecimiento polinomial y exponencial

$$f_{\mathscr{A}}(n) \to +\infty$$

$$n \to +\infty$$

$$\lim_{n \to +\infty} \frac{P(n)}{a^n} = 0, \quad a > 1$$

Complejidad computacional

Clase P/NP

- **Clasificación** de los **problemas**

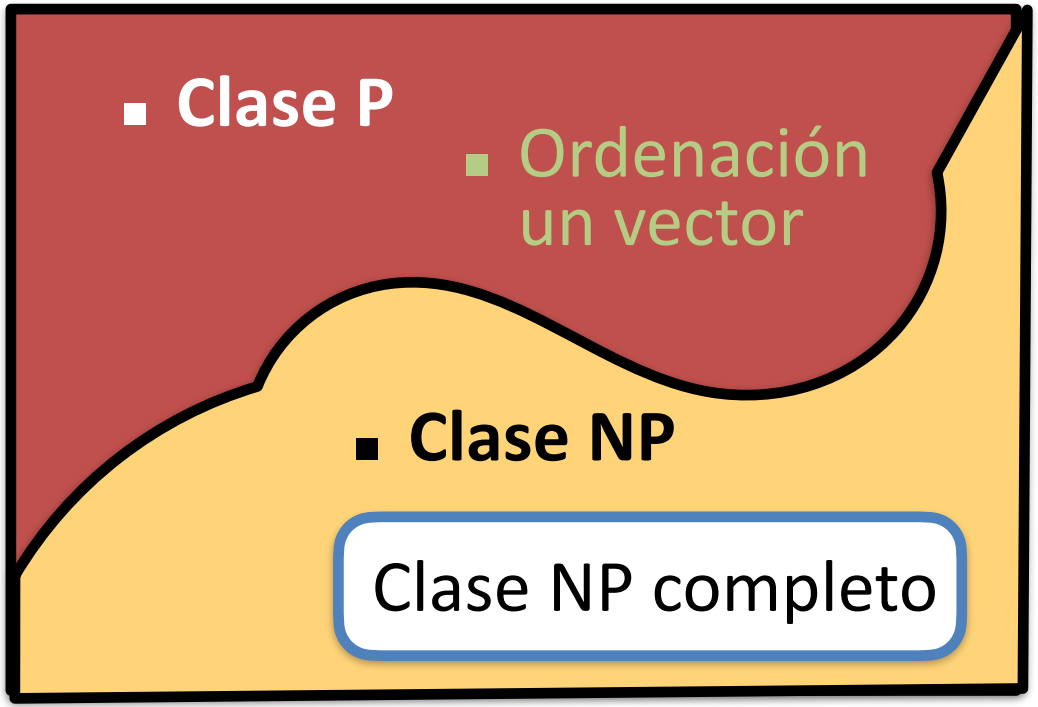

Complejidad computacional

Clase P/NP

¿ $P = NP$?

Clay Mathematics Institute

Complejidad computacional

Actividad

Considerar ordenación de un vector de **n=1000**

Método	Operaciones
Método burbuja $O(n^2)$	1 millón
Ordenación por mezcla $O(n \log_{10} n)$	3000
Ordenación Radix (recursiva) $O(n^3)$	1000 millones

Complejidad computacional

Actividad

Considerar ordenación de un vector de **n=1000**

Método	Operaciones
Ordenación Shell $O(n^{1.5})$	31623
Ordenación exhaustiva $O(n!)$	$\approx +\infty$ desde un punto de vista práctico

Complejidad computacional

- Tiempo de ejecución
- P/NP

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de Big_Data

Curso Especialización Inteligencia_Artificial y Big_Data

Complejidad computacional y escalabilidad

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de Big_Data

Curso Especialización Inteligencia_Artificial y Big_Data

Complejidad Escalabilidad

Actividad

Sistema criptográfico de clave pública
RSA (*Rivest, Shamir y Adleman*)

$$n = p \cdot q$$

p, q primos

$$33 = 3 \cdot 11$$

Complejidad Escalabilidad

Complejidad

Algoritmo factorizar en primos estado-del-arte

$$f_{\mathcal{A}}(n) = 10^{\sqrt{n \cdot \log_{10}(n)}}$$

Complejidad Escalabilidad

Crecimiento polinomial/exponencial

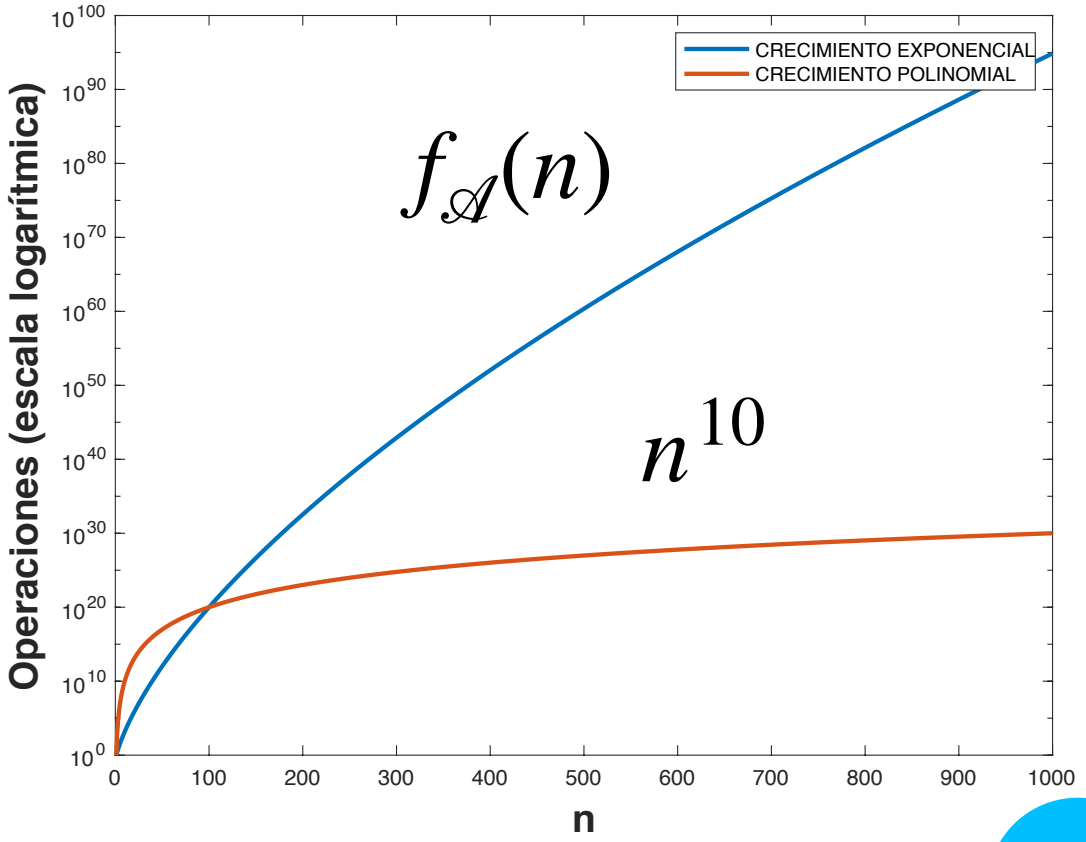

Complejidad Escalabilidad

Algoritmo factorizar en primos estado-del-arte

Complejidad

X=12345678901234567890123456789O

X tiene **n**=30 dígitos

$$f_{\mathcal{A}}(30) = 10^{\sqrt{30 \cdot \log_{10}(30)}}$$

$$= 1.2318 * 10^{08}$$

Complejidad
Escalabilidad

Roadrunner
IBM

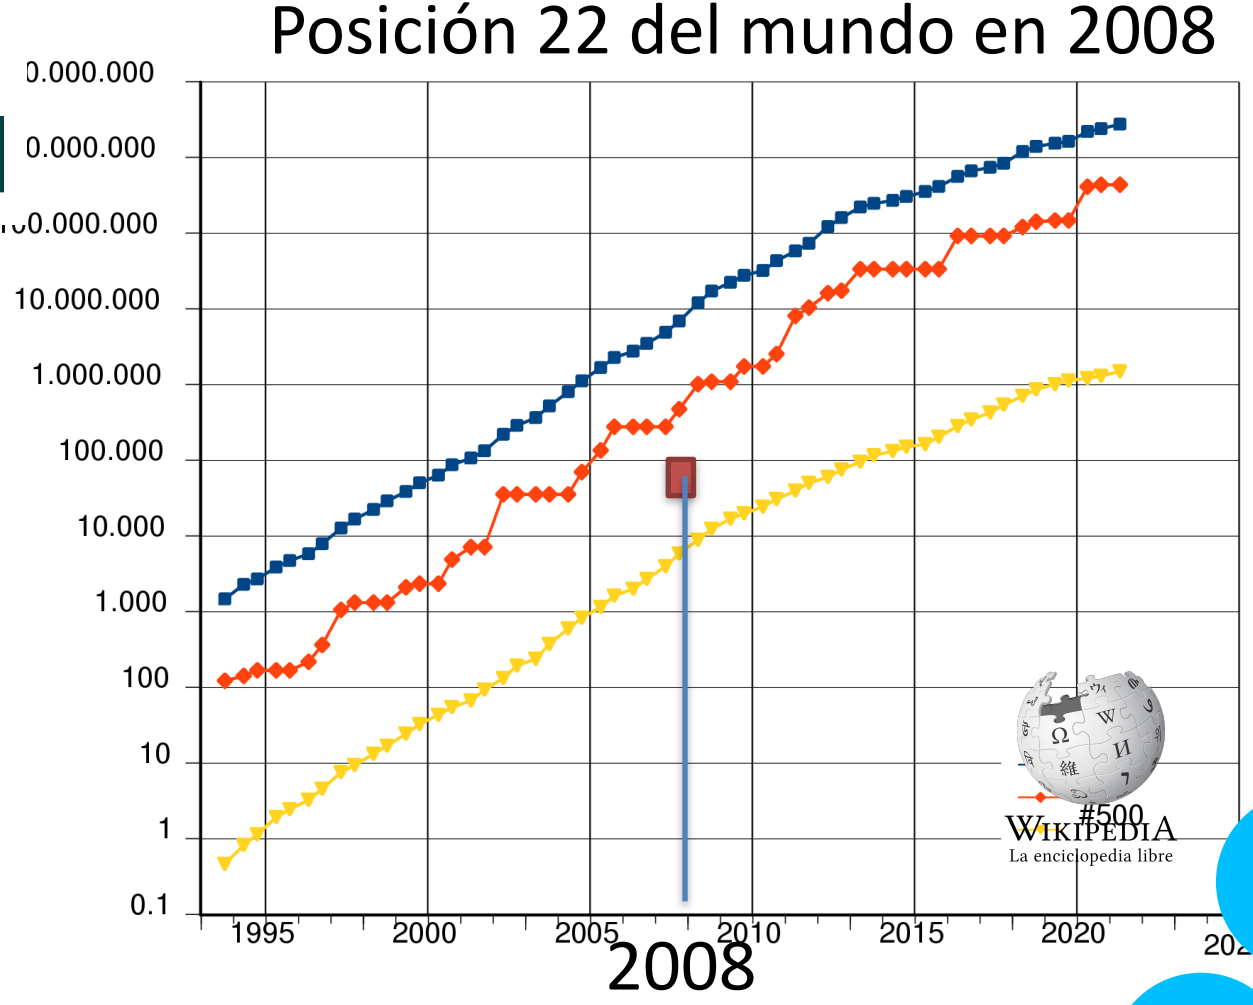

Complejidad
Escalabilidad

Roadrunner
IBM

VelocidadCPU

$=1.05 * 10^{15}$ operaciones / s

= 1.105 Petaflops

Complejidad Escalabilidad

Roadrunner

IBM

- ¿Cuánto **tiempo** requiere factorizar un número con n=**50 cifras**?

$$f_{\mathcal{A}}(50) = 10^{\sqrt{50 \cdot \log_{10}(50)}} = 1.0316 \cdot 10^{12}$$

$$\frac{f_{\mathcal{A}}(50)}{\text{VelocidadCPU}} = 9.3362 \cdot 10^{-04} \text{ segundos}$$

Complejidad Escalabilidad

Roadrunner

IBM

- ¿Qué tamaño máximo **n** se puede factorizar en **un año**?

$nOp =$ VelocidadCPU* segundos en un año

$$f_{\mathcal{A}}(n) \leq nOp$$

Complejidad
Escalabilidad

costeComputacional.py

```
from math import *
VelocidadCPU = 1.105 * 10 ** 15
n=1
fA=1
nOp=VelocidadCPU *24 * 60 * 60 *365
while  fA <= nOp:
    n = n+1
    fA =10**( pow(log(n,10),0.5))

print(n-1)
```

Complejidad Escalabilidad

Escalabilidad

- ¿Qué tamaño máximo **n** se puede factorizar en **un año**?
  - **n**= **217**

- **2***VelocidadCPU
  - **n**= 217+**5**

Complejidad Escalabilidad

Escalabilidad

75 millones Euros

- 12345678901234567890123456789012345678901234567890123456789012345678901234567890123456789012345678901234567890123456789012345678901234567

- 12345678901234567890123456789012345678901234567890123456789012345678901234567890123456789012345678901234567890123456789012345678901234567

150 millones Euros

Complejidad computacional y escalabilidad

- Máquina / Algoritmo

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de Big_Data

Curso Especialización Inteligencia_Artificial y Big_Data

Divide y vencerás

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de
Big_Data

Curso Especialización
Inteligencia_Artificial y
Big_Data

Sistemas Big Data

Motivación

Coste exponencial es inabordable

- A efectos prácticos $O(n^3)$ no es escalable
  - **n=1000 números float**

Memoria

- 1000 datos*64 Bytes
- 1MB=1.048.576 Bytes
- 0.06 MB

Sistemas Big Data

Motivación

Coste exponencial es inabordable

- A efectos prácticos $O(n^3)$ no es escalable
  - **n=1000 números float**

Número de operaciones

- $1000^3 = 1000 * 10^6$ =
- 1000 millones de operaciones

Sistemas Big Data

Motivación

Coste exponencial es inabordable

- A efectos prácticos $O(n^3)$ no es escalable
  - **n=10000 números float**

Número de operaciones

$$10000^3 = (10 \cdot 1000)^3 = 10^3 1000^3$$

$$= 1 \text{ billón de operaciones}$$

Sistemas Big Data

Divides y vencerás

Particionamiento datos

Resultados intermedios

Output

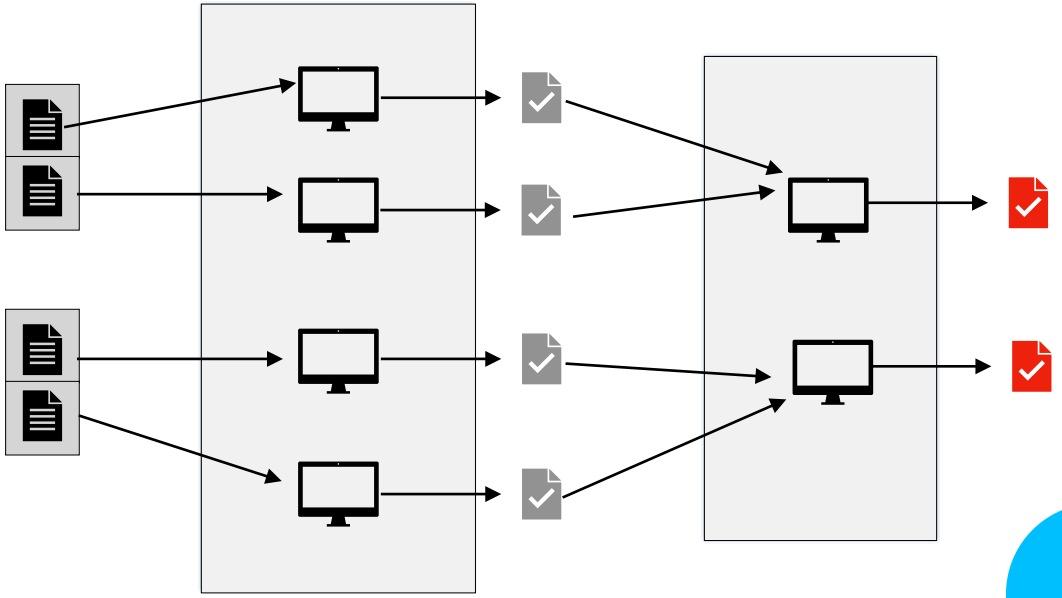

Sistemas Big Data

Computación distribuida

- n=1000 números float
  K=100 procesadores
  m=10 tamaño submuestra

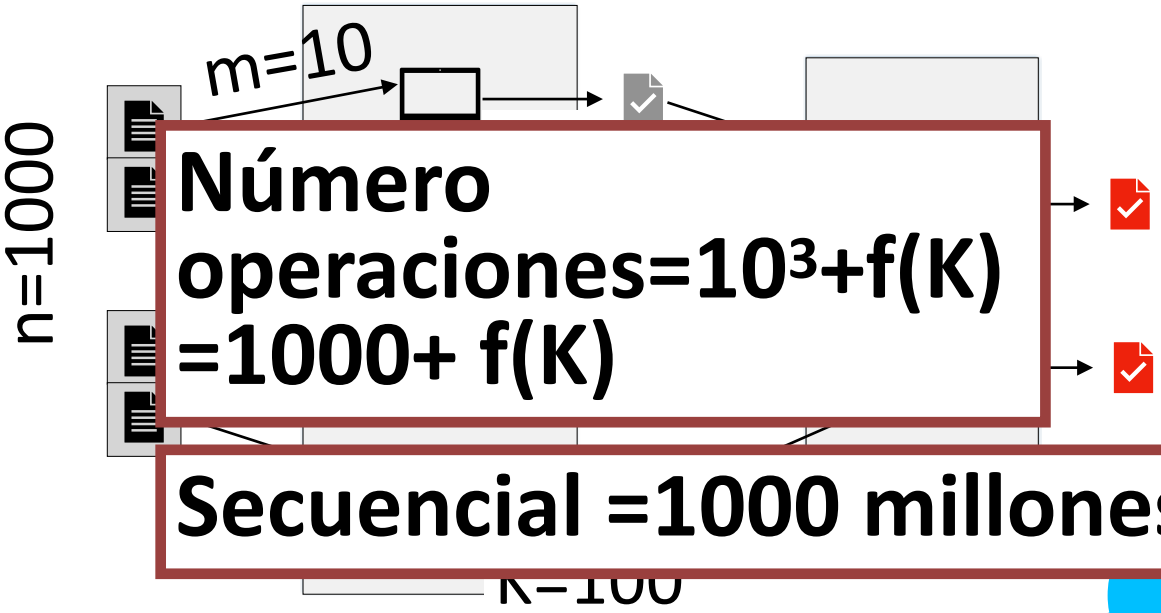

Número operaciones=10^3+f(K) =1000+ f(K)

Secuencial =1000 millones

Sistemas Big Data

Cálculo Media

$$\bar{x} = \frac{x_1 + \ldots + x_n}{n}$$

41	9	32	6	12

$$\bar{x} = \frac{41 + 9 + 32 + 6 + 12}{5} = \frac{100}{5} = 20$$

Sistemas Big Data

Computación distribuida

Particionamiento datos

Resultados intermedios

Output

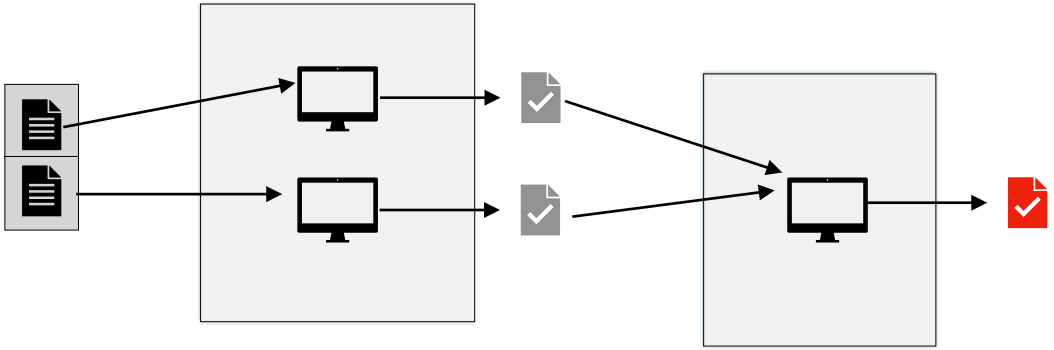

Sistemas Big Data

Cálculo Media

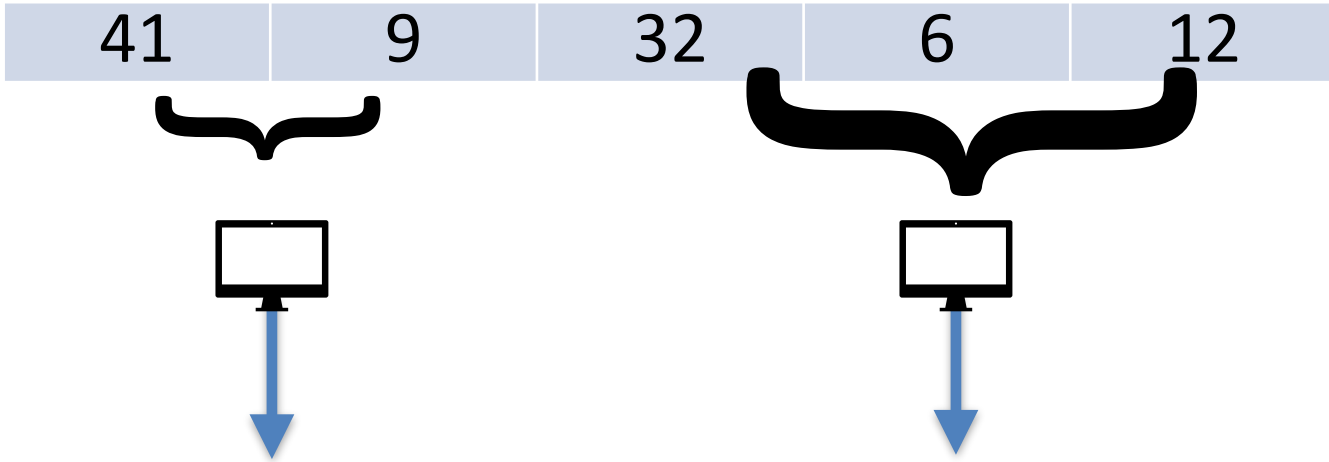

$$\bar{x}_1 = \frac{41+9}{2} = \frac{50}{2} = 25 \qquad \bar{x}_2 = \frac{32+6+12}{3} = \frac{50}{3}$$

Sistemas Big Data

- Cálculo Media

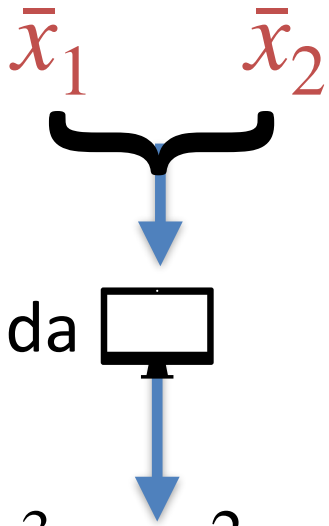

$$\bar{x} = \frac{2}{5}\bar{x}_1 + \frac{3}{5}\bar{x}_2 = \frac{2}{5}25 + \frac{3}{5}\frac{50}{3} = 20$$

Sistemas Big Data

Complejidad Secuencial

$$\bar{x} = \frac{x_1 + \ldots + x_n}{n}$$

O(n) secuencial

n=m*K; particionamos en grupos de m datos

Sistemas Big Data

Complejidad

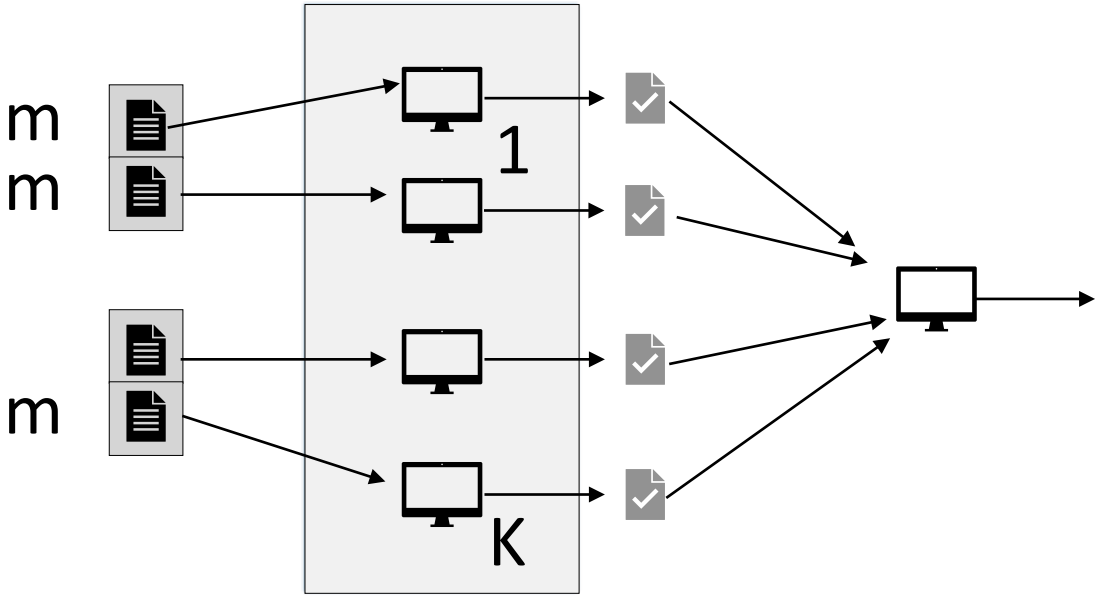

Distribuido	O(m) + O(K)
Secuencial	O(m*K)

Divide y vencerás

- $O(n^3)$ no es escalable
- Computación distribuida

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de Big_Data

Curso Especialización Inteligencia_Artificial y Big_Data

Proceso extracción información

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de Big_Data

Curso Especialización Inteligencia_Artificial y Big_Data

Proceso extracción información

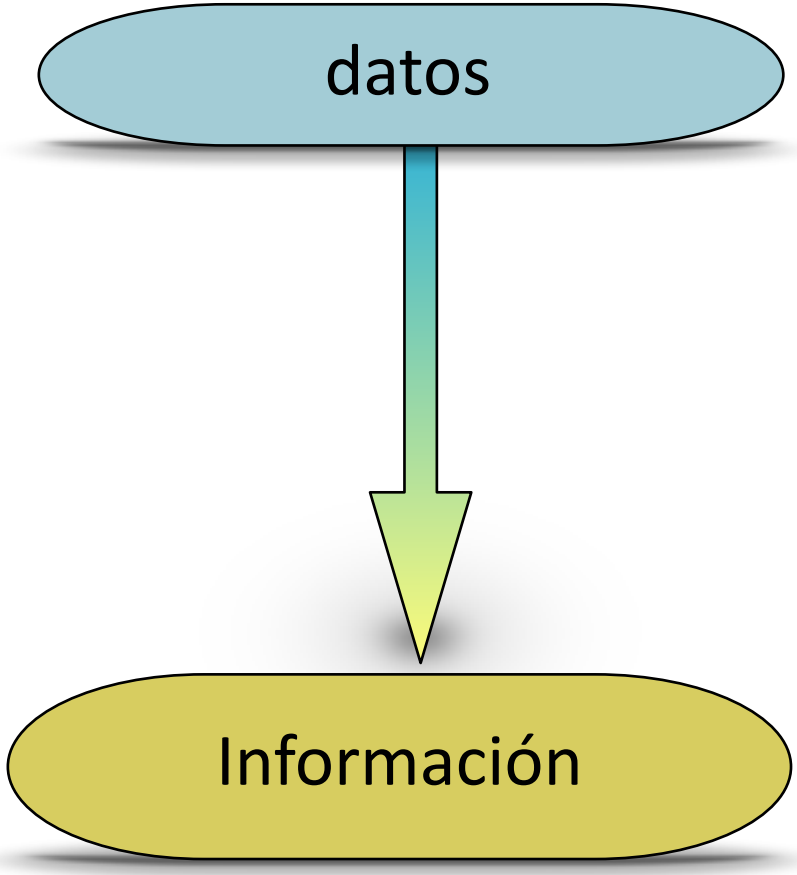

Proceso extracción información

Etapas

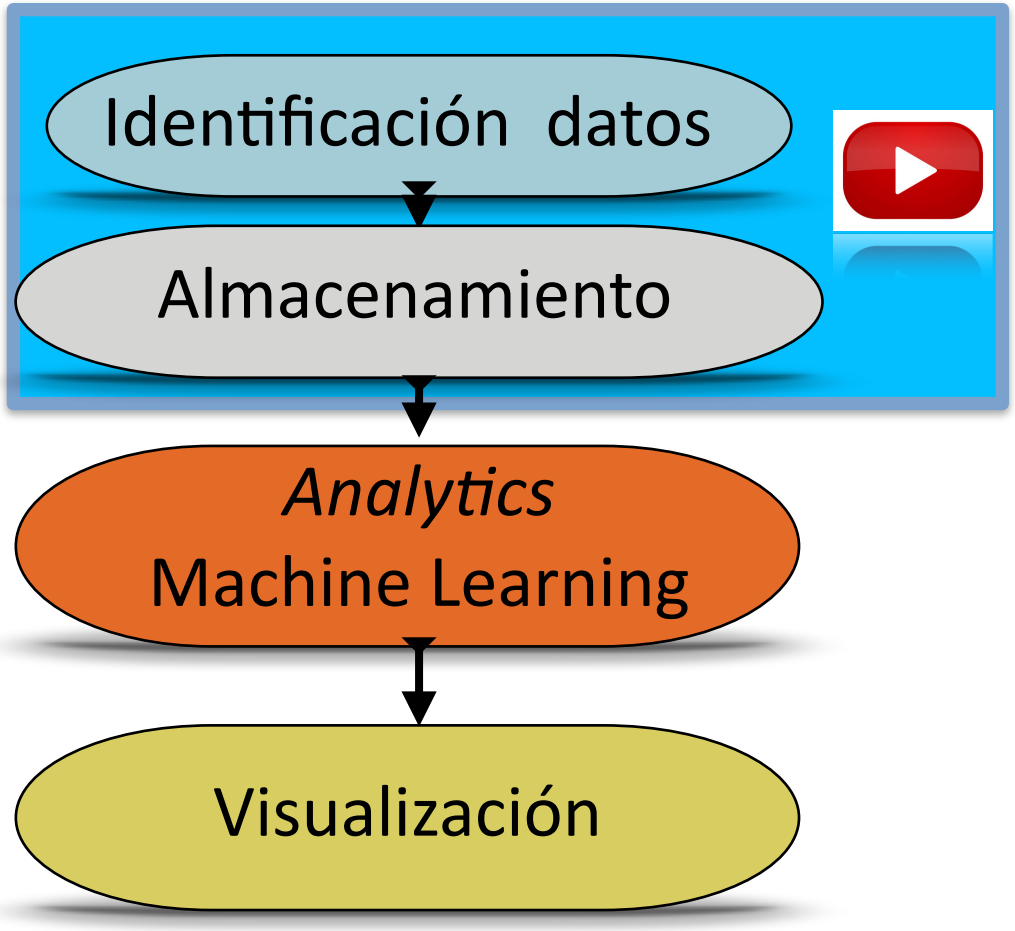

Proceso extracción información

1.- Identificación datos

Proceso extracción información

Tipología datos

- Datos estructurados
- Datos **NO** estructurados
- Datos **SEMI** estrucuturados

Proceso extracción información

Tipología datos

- **Datos estructurados**

Proceso extracción información

Tipología datos

- Datos **NO** estructurados

Proceso extracción información

Tipología datos

- Datos **semi-**estructurados

Proceso extracción información

2.-Almacenamiento

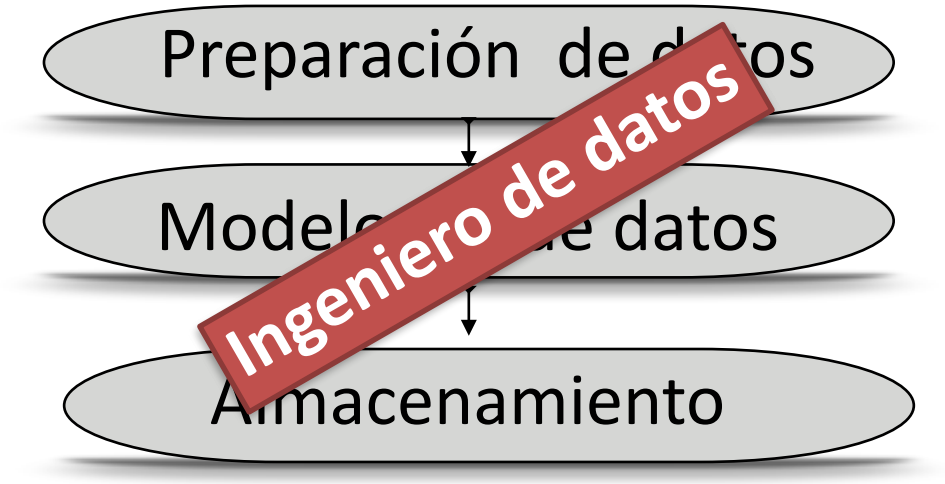

Proceso extracción información

2.-Almacenamiento

Preparación de datos

- Depuración
- Criba
- Valores faltantes

Proceso extracción información

2.-Almacenamiento

Modelo de de datos

- Notación
- Restricciones de integridad
- Operaciones I/O

Proceso extracción información

2.-Almacenamiento

Modelo de de datos

- Conceptual
- Lógico
- Físico

Proceso extracción información

2.-Almacenamiento

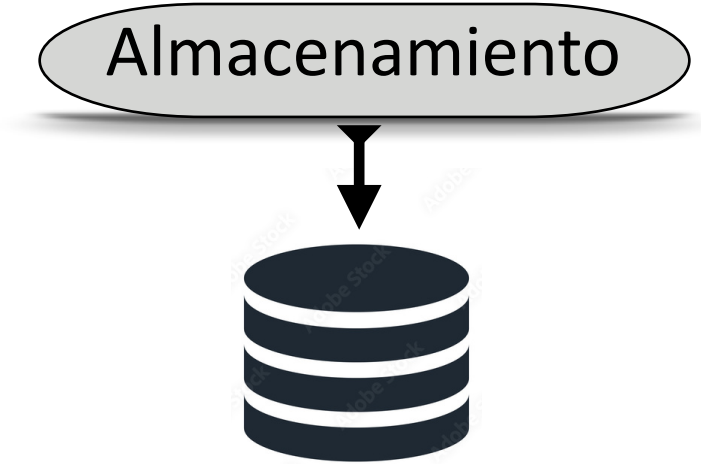

Proceso extracción información

- Proceso
- Etapas identificación y almacenamiento

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de Big_Data

Curso Especialización Inteligencia_Artificial y Big_Data

Aprendizaje automático

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de Big_Data

Curso Especialización Inteligencia_Artificial y Big_Data

Proceso extracción información

Recordatorio

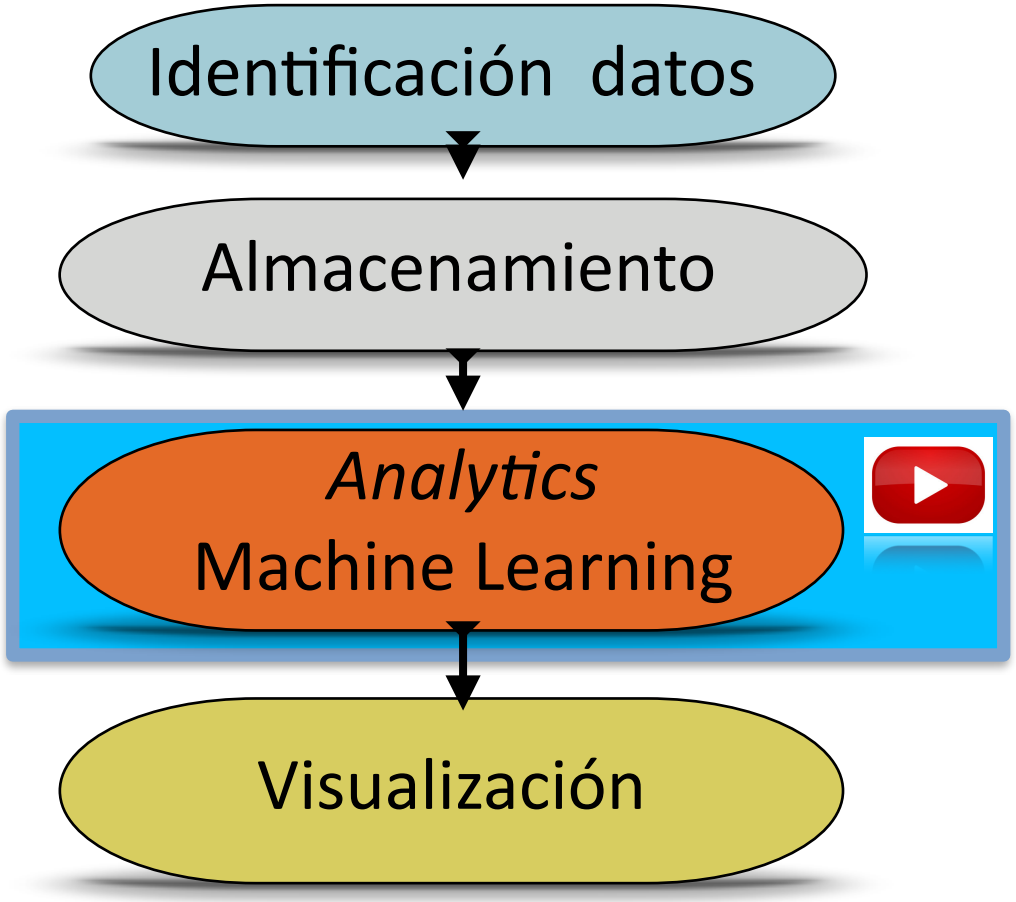

Aprendizaje automático

Modelo

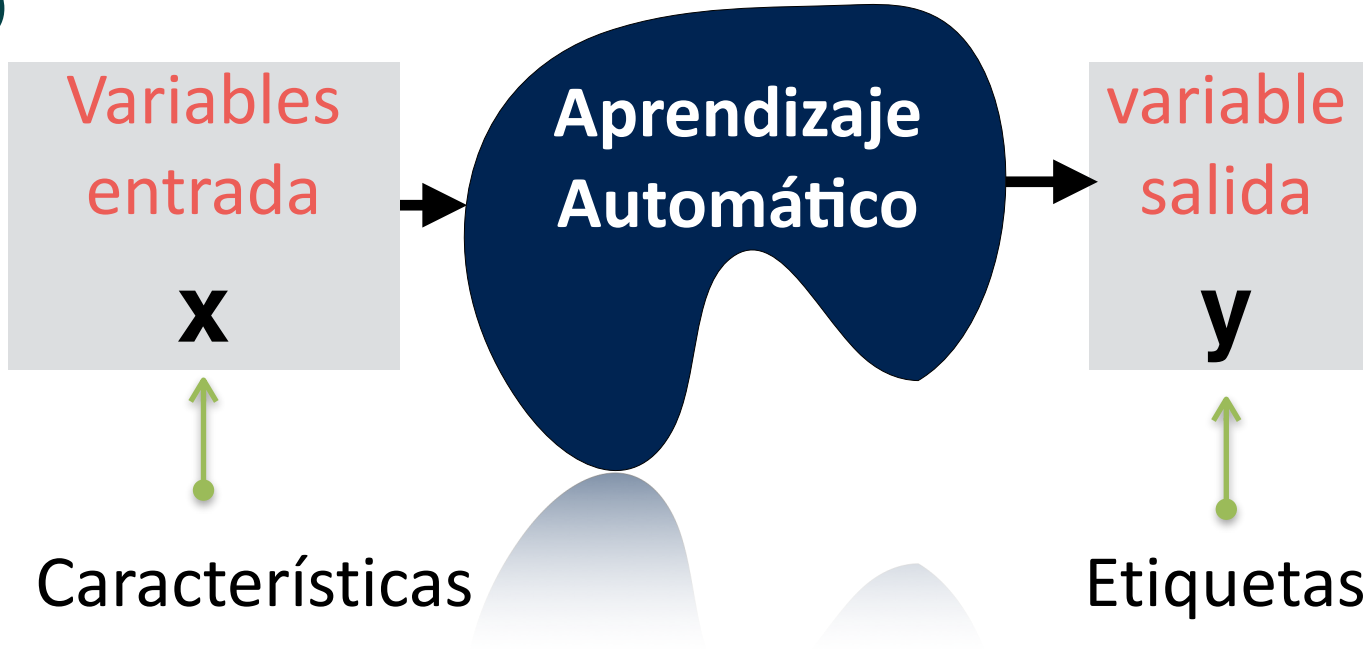

Aprendizaje automático

Modelo

8

6

3.5

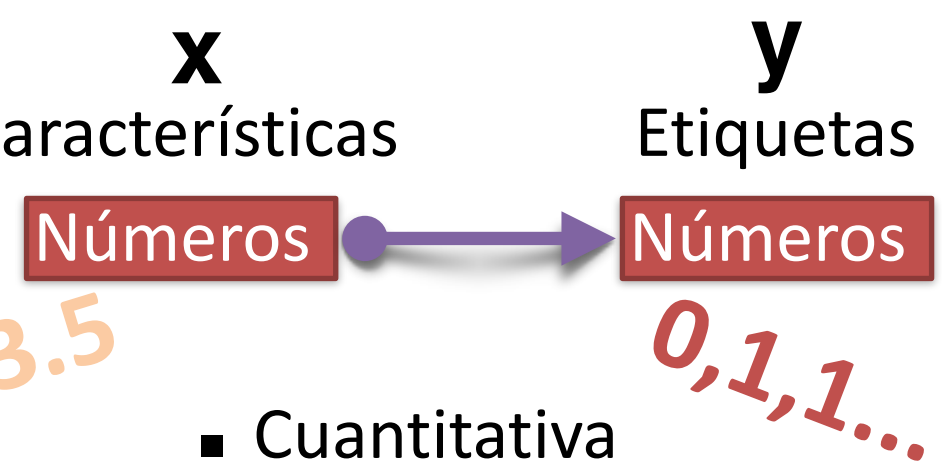

- Cuantitativa
- Ordinal
- Cualitativa

Aprendizaje automático

Clasificación

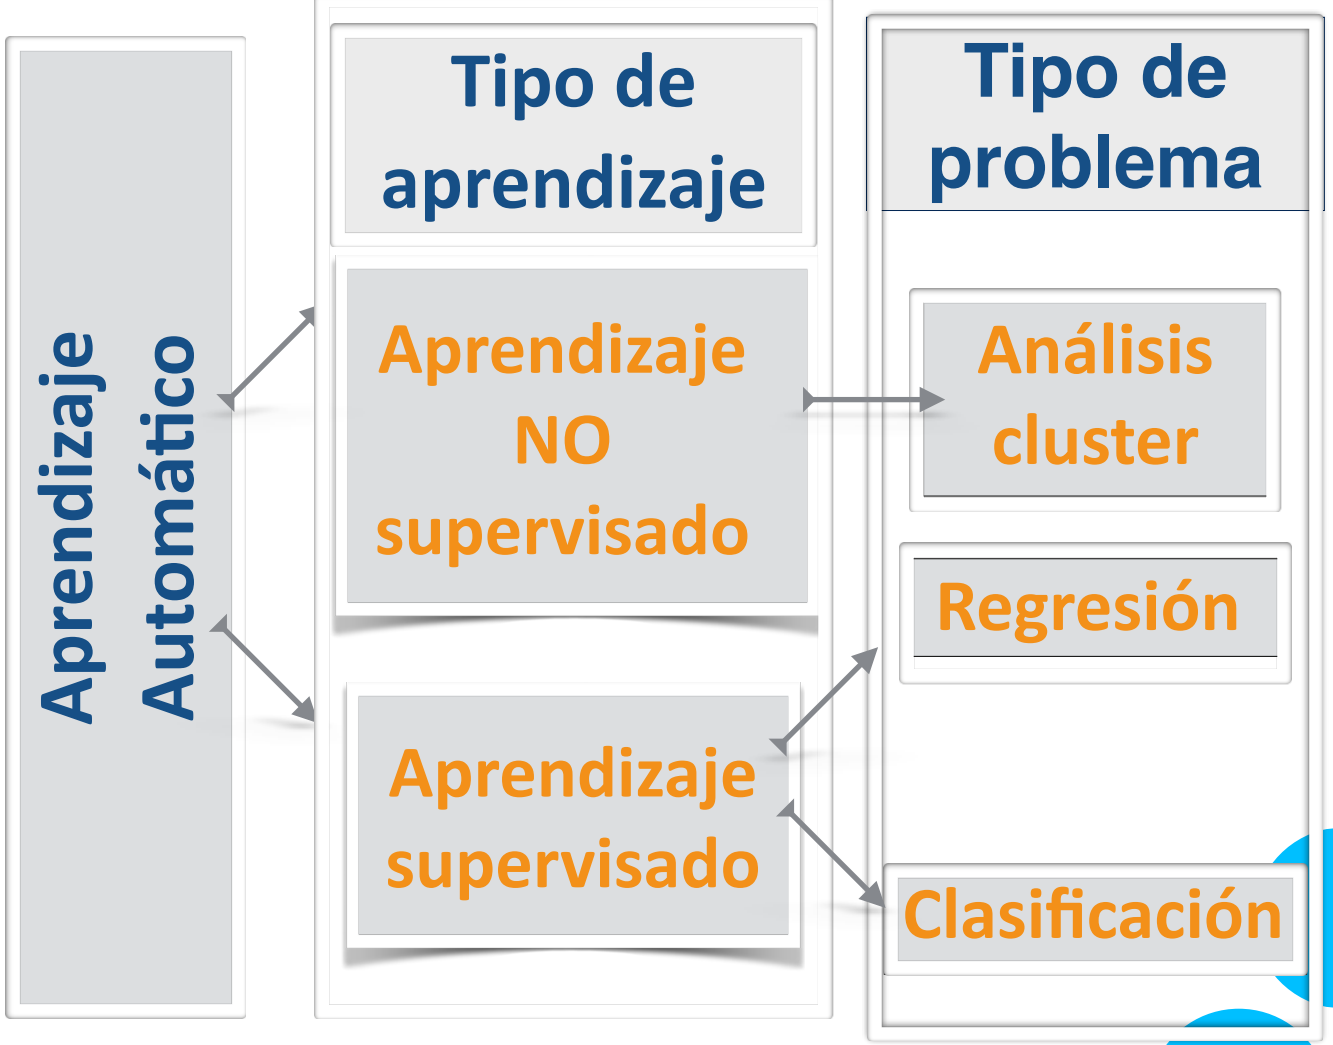

Aprendizaje automático

Datos estructurados

Características

Etiquetas

Números

Números

8

6

3.5

0,1,1...

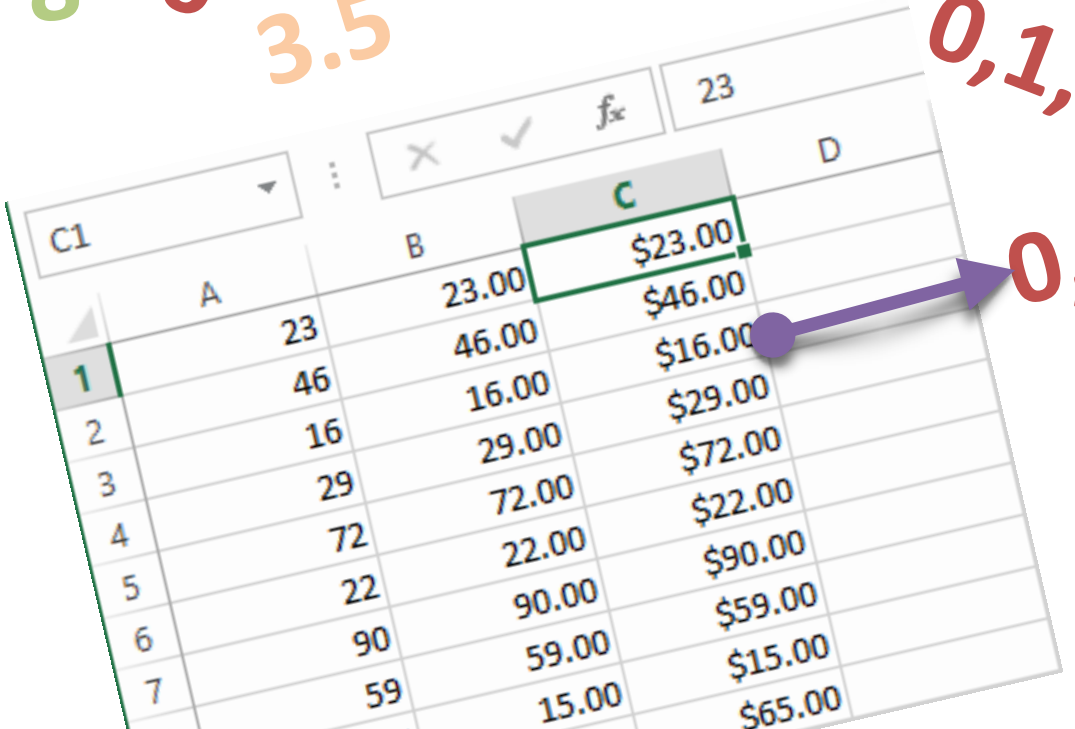

0,1,1...

Aprendizaje automático

Datos NO estructurados

8 6 3.5

Características → Etiquetas

Números → Números

0,1,1...

¿ texto 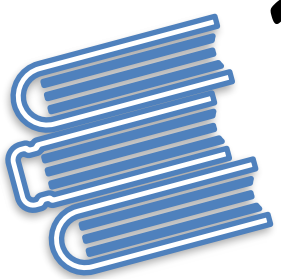 ? → 0,1,1..

Aprendizaje automático

Texto

- Análisis de sentimientos
- Entidades con nombre
- Extracción eventos

Aprendizaje automático

Imagenes

- **Extracción de textos y objetos**

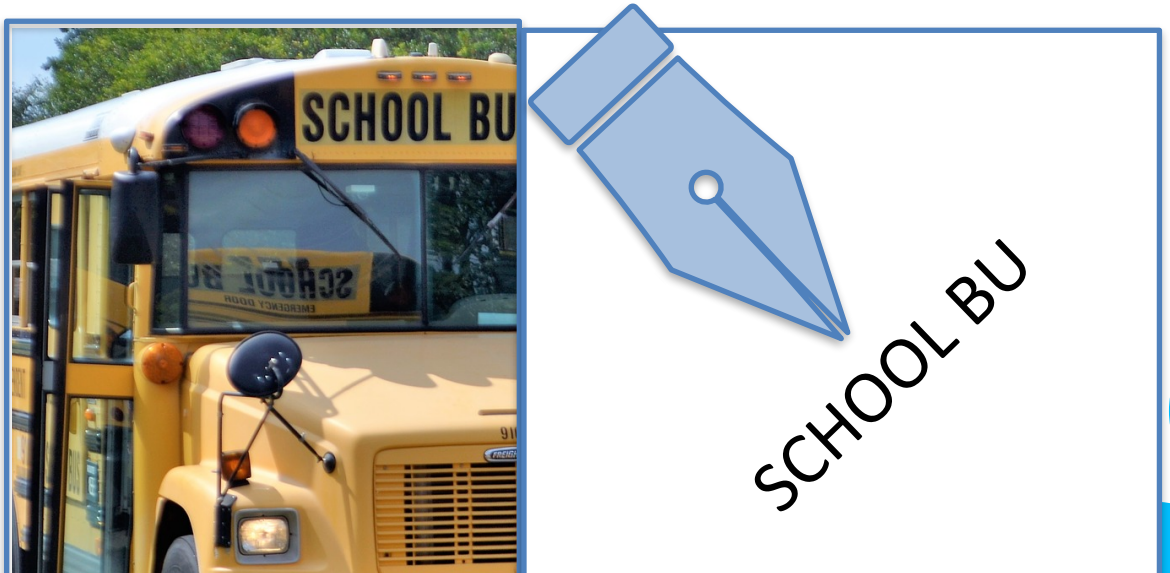

Aprendizaje automático

Imagenes

- Extracción de textos y objetos
- **Entendimiento de imágenes**

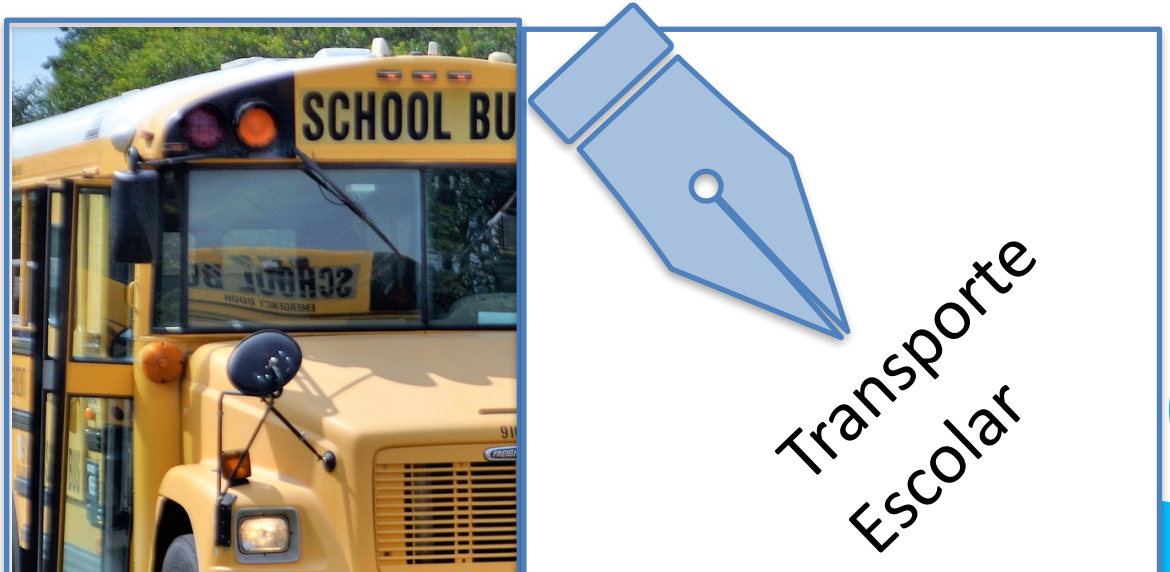

Aprendizaje automático

Imagenes

- Extracción de textos y objetos
- Entendimiento de imágenes
- **Reconocimiento facial**

Ricardo García

Aprendizaje automático

Imagenes

- Extracción de textos y objetos
- Entendimiento de imágenes
- Reconocimiento facial
- Análisis de imágenes geoespaciales

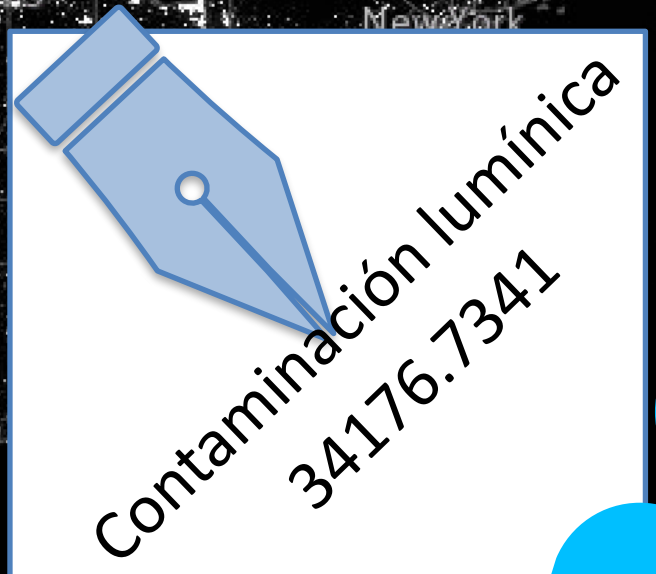

Aprendizaje automático

Audio

- **Reconocimiento de audio**

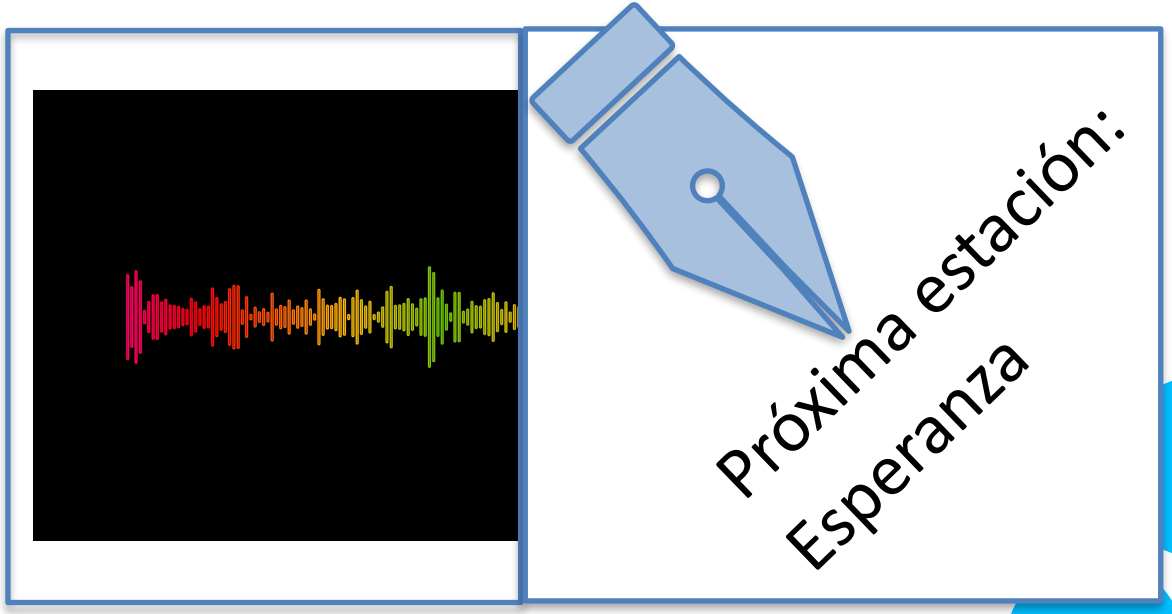

Aprendizaje automático

Audio

- Reconocimiento de audio
- **Extracción de características**

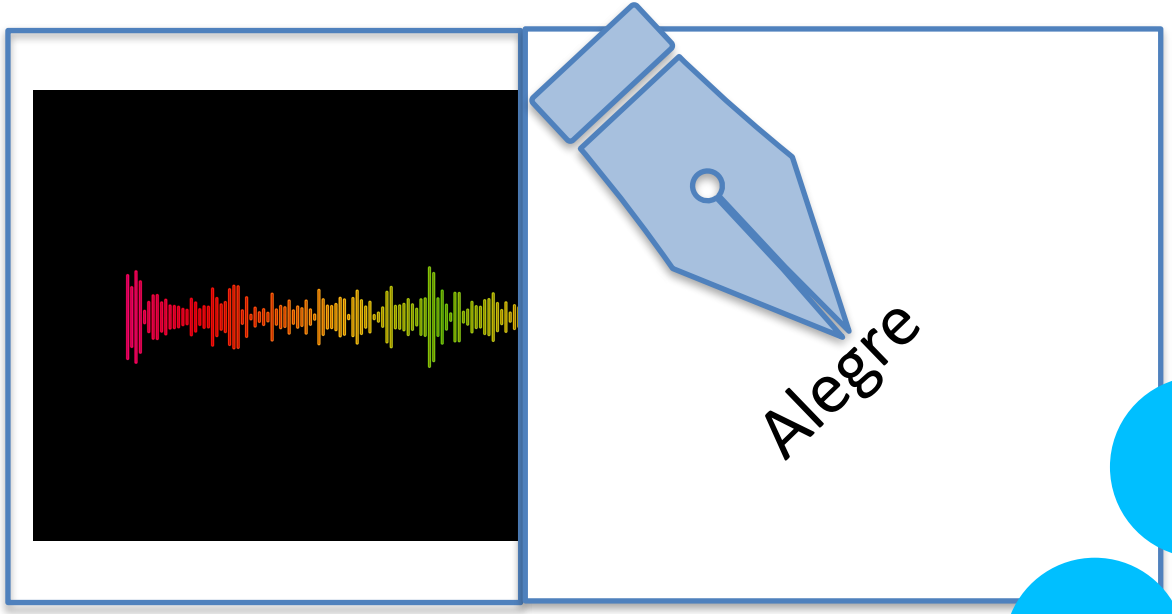

Aprendizaje automático

Video

- **Creación de resúmenes automáticos**

Aprendizaje automático

Video

- Creación de resúmenes automáticos
- **Reconocimiento de lugares, objetos o acciones**

Aprendizaje automático

Conclusión 1

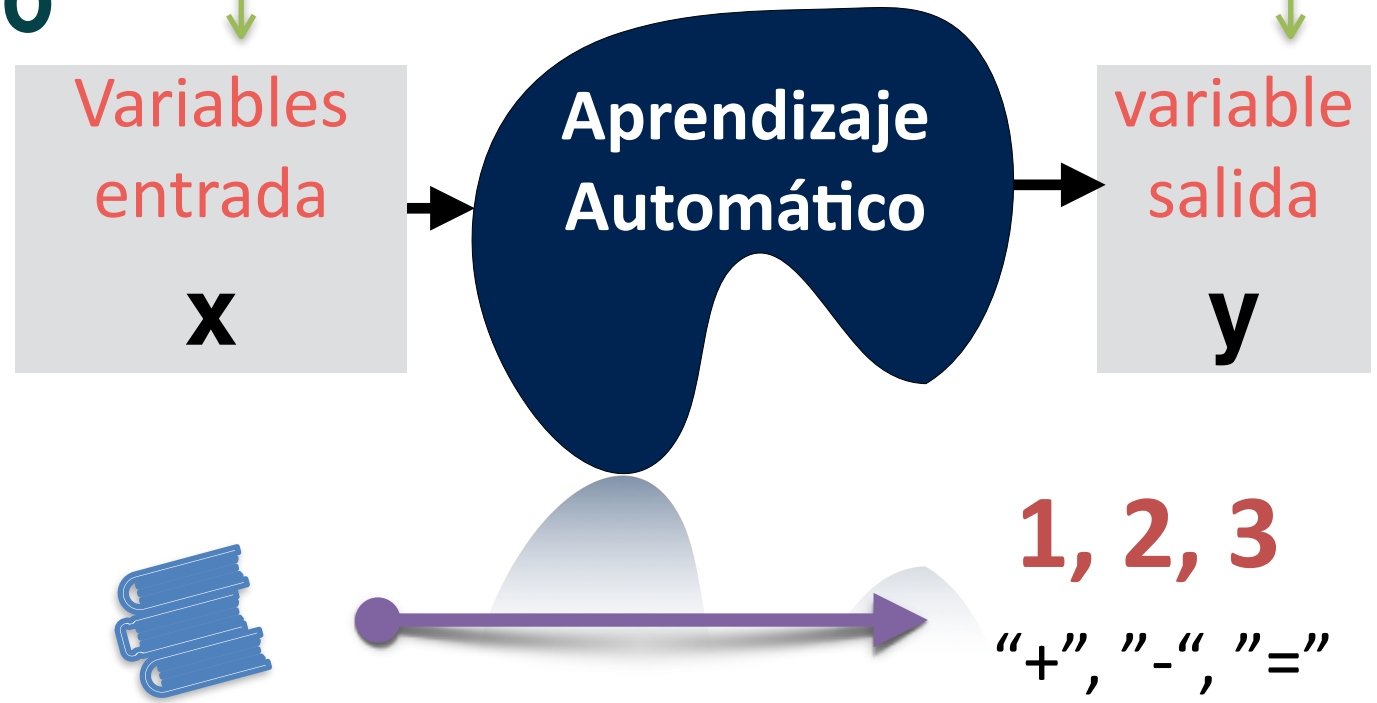

Aprendizaje automático

Conclusión 1

Características

Etiquetas

Variables entrada

x

Aprendizaje Automático

variable salida

y

1, 2, 3

"Perro",

"Gato", "Bus"

Aprendizaje automático

Idea 2

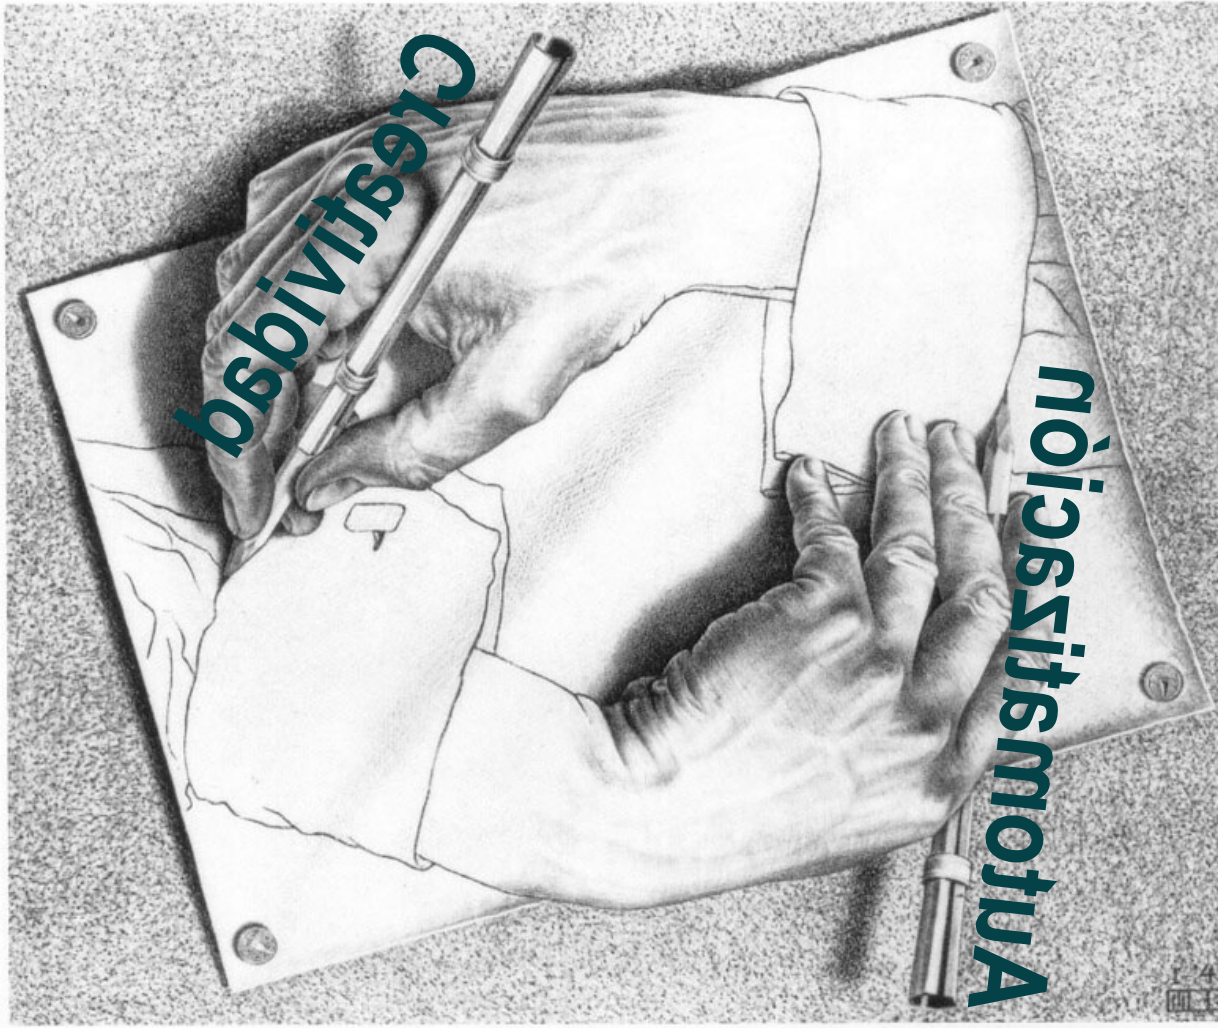

Aprendizaje automático

- Clasificación modelos
- Datos NO estructurados

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de Big_Data

Curso Especialización Inteligencia_Artificial y Big_Data

Visualización

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de
Big_Data

Curso Especialización
Inteligencia_Artificial y
Big_Data

Procesos extraccción información

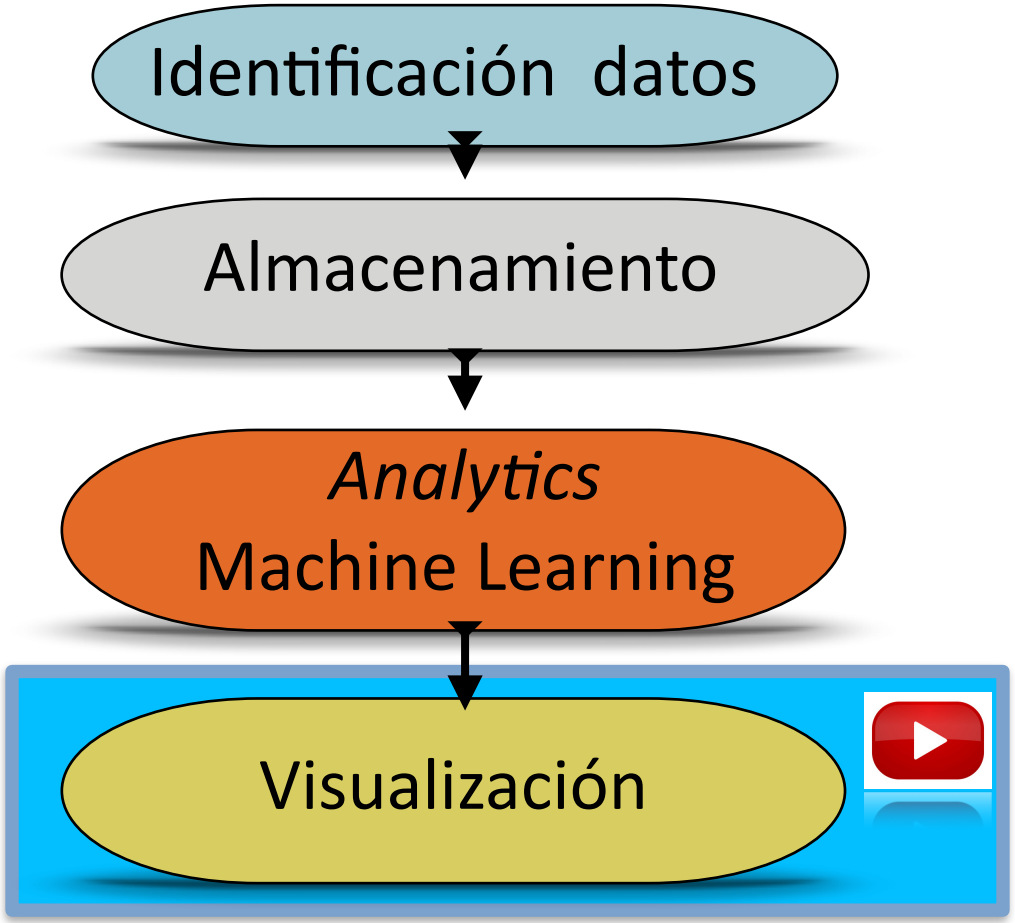

Visualización

¿Qué es?

Visualización

Datos estructurados

Finalidad

- **explicar** los datos existentes
- realizar **predicciones**

Visualización

Datos NO estructurados

Finalidad

- comunicar
- evaluación
- interpretar

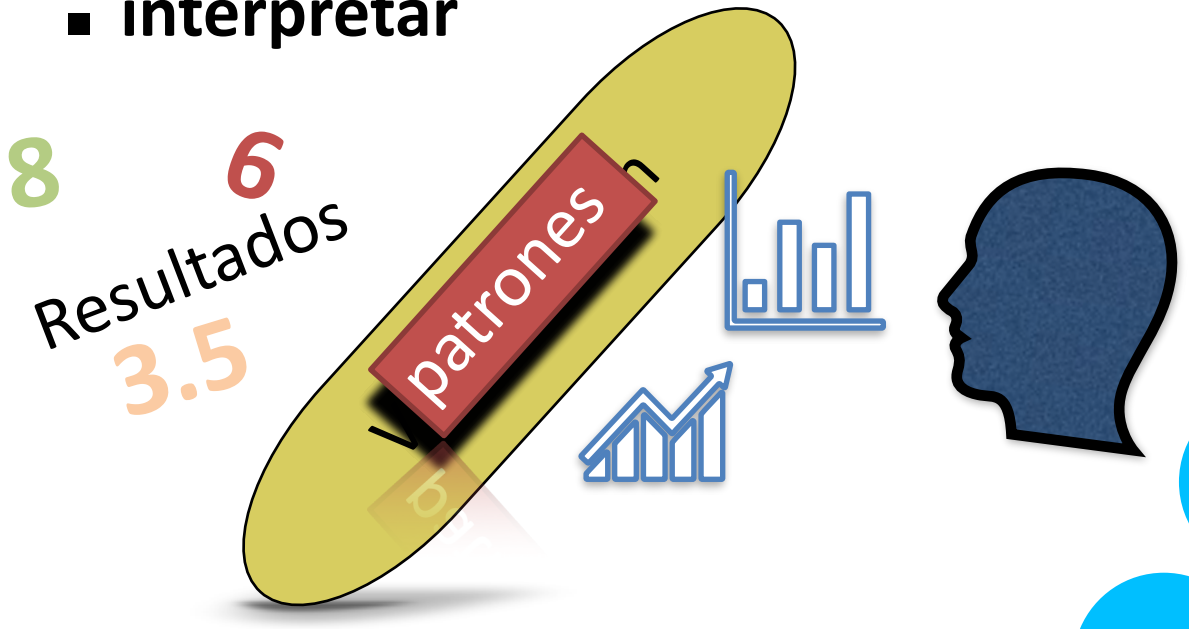

Visualización

Finalidad

- **interpretación**
- **evaluación**
- **comunicar**

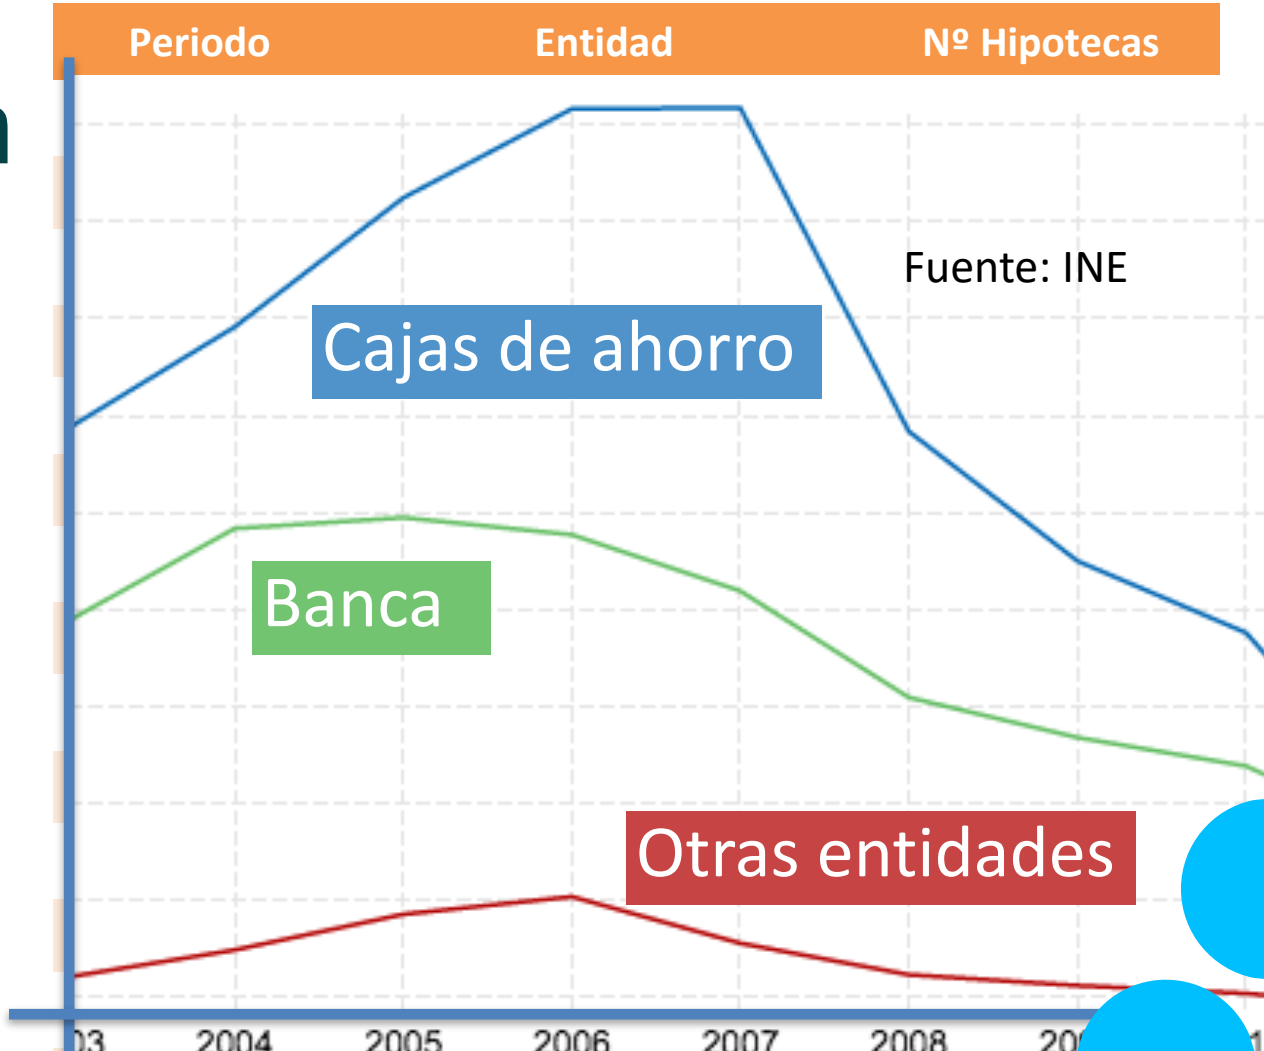

Visualización

Volumen

- **Resumir** bases de datos masivas
- **Identificación patrones**
- **Identificación** de **datos** relevantes

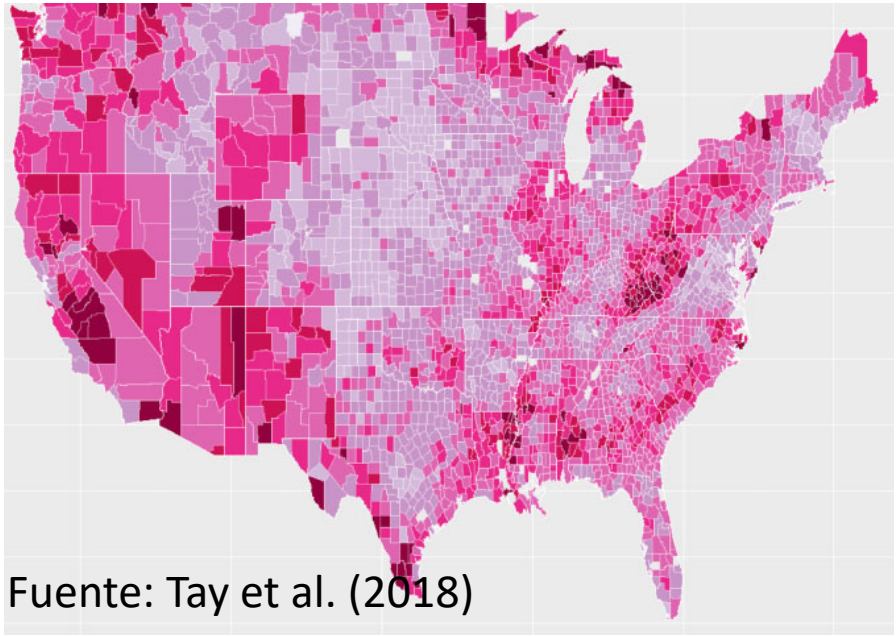

Fuente: Tay et al. (2018)

Visualización

Volumen

Resumen / identificación

- **Nivel de agregación**

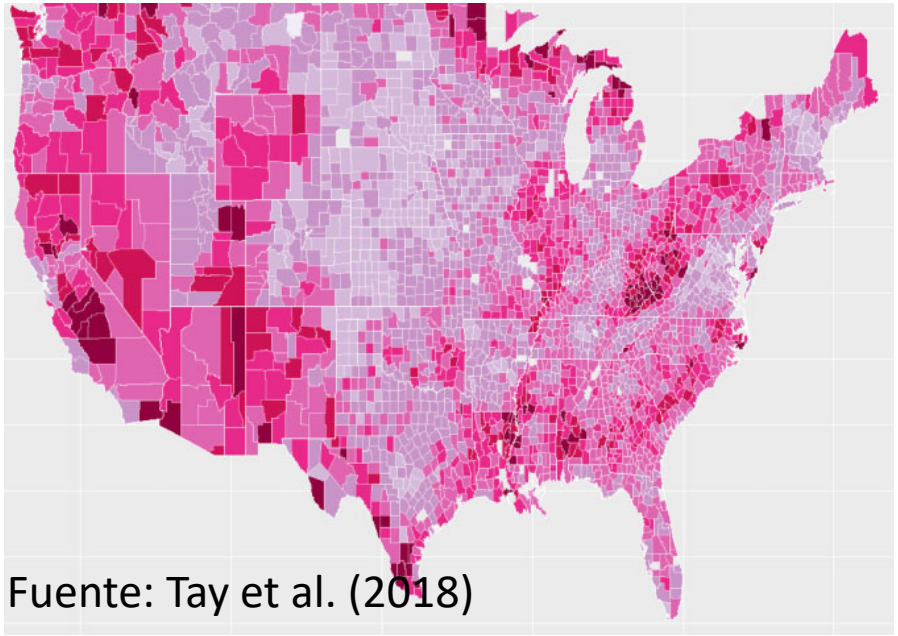

Fuente: Tay et al. (2018)

Visualización

Variedad

- **Integración** en una visión de análisis

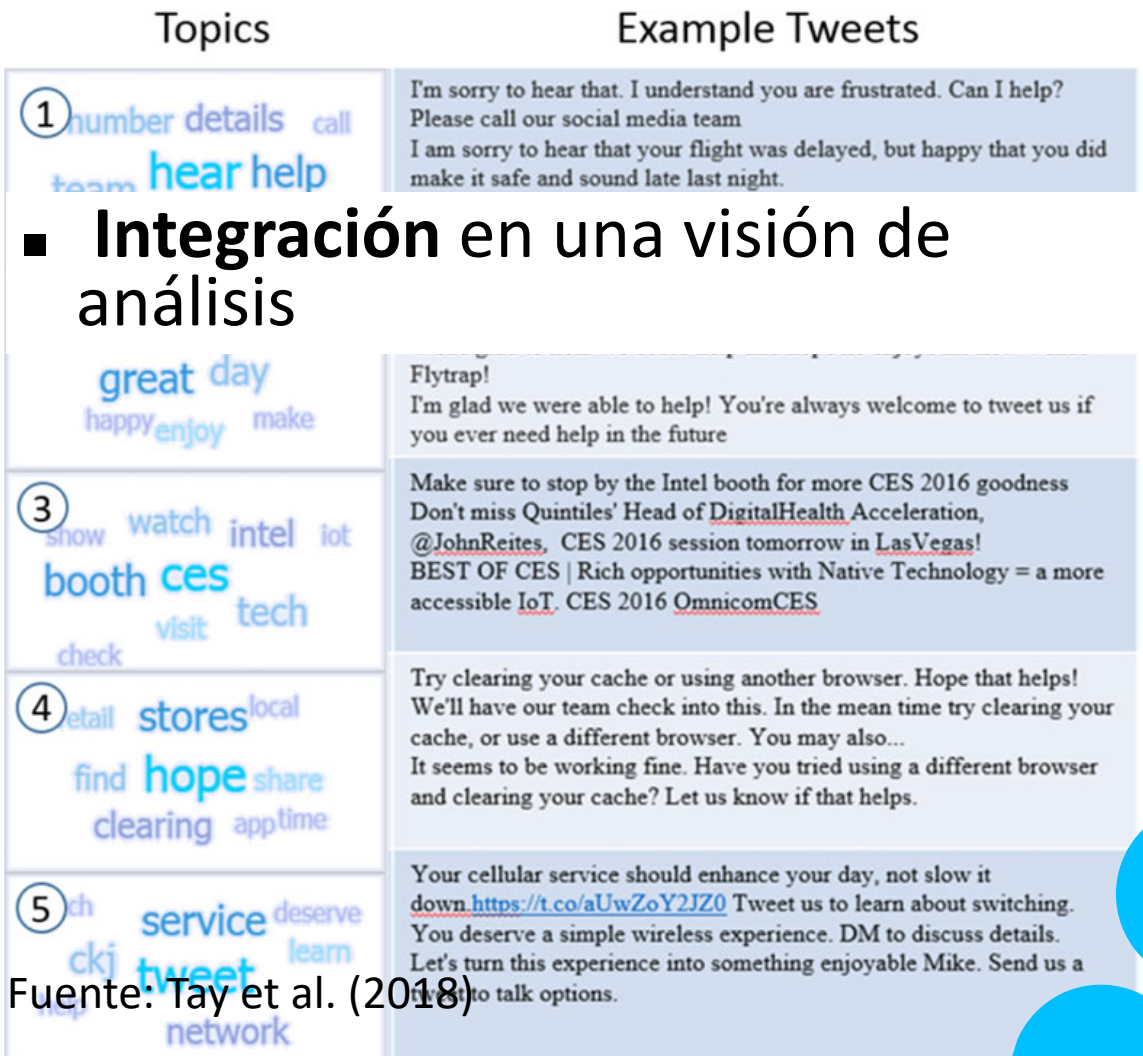

Fuente: Tay et al. (2018)

Visualización

Velocidad

- **Inmediatez**

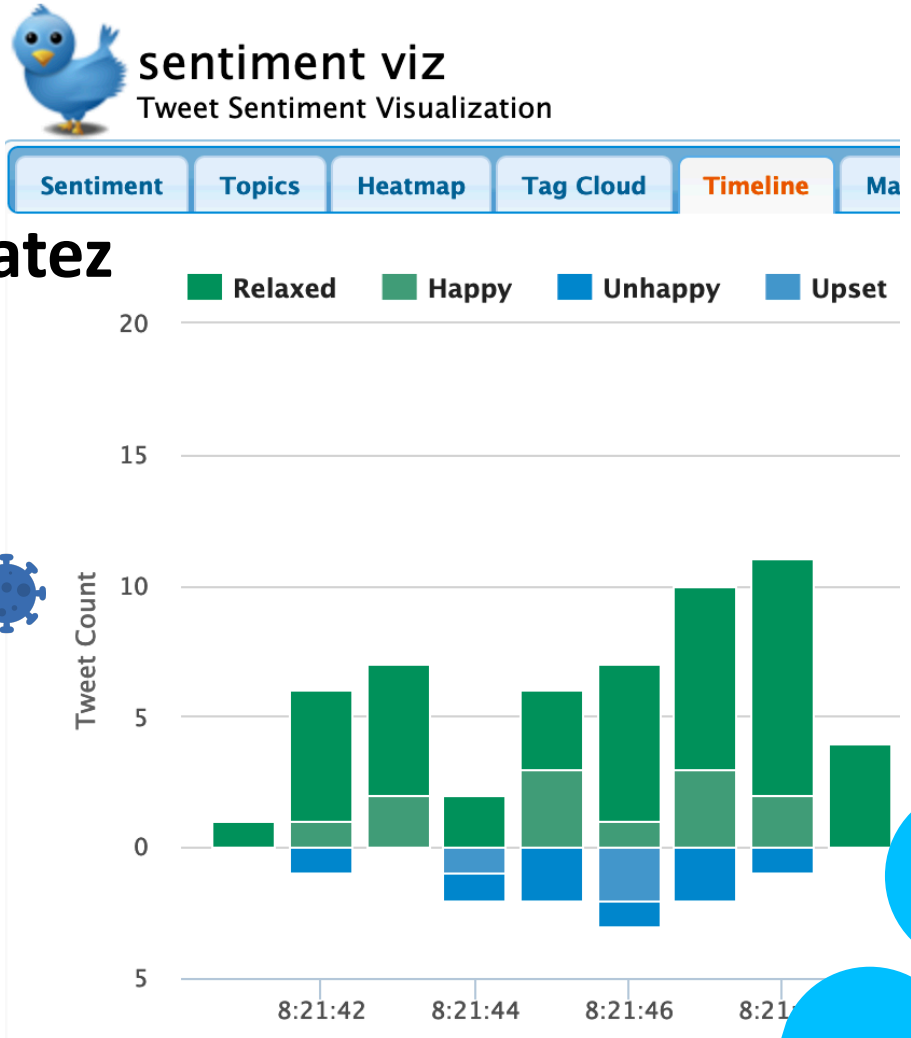

Visualización

Cuadro de mando

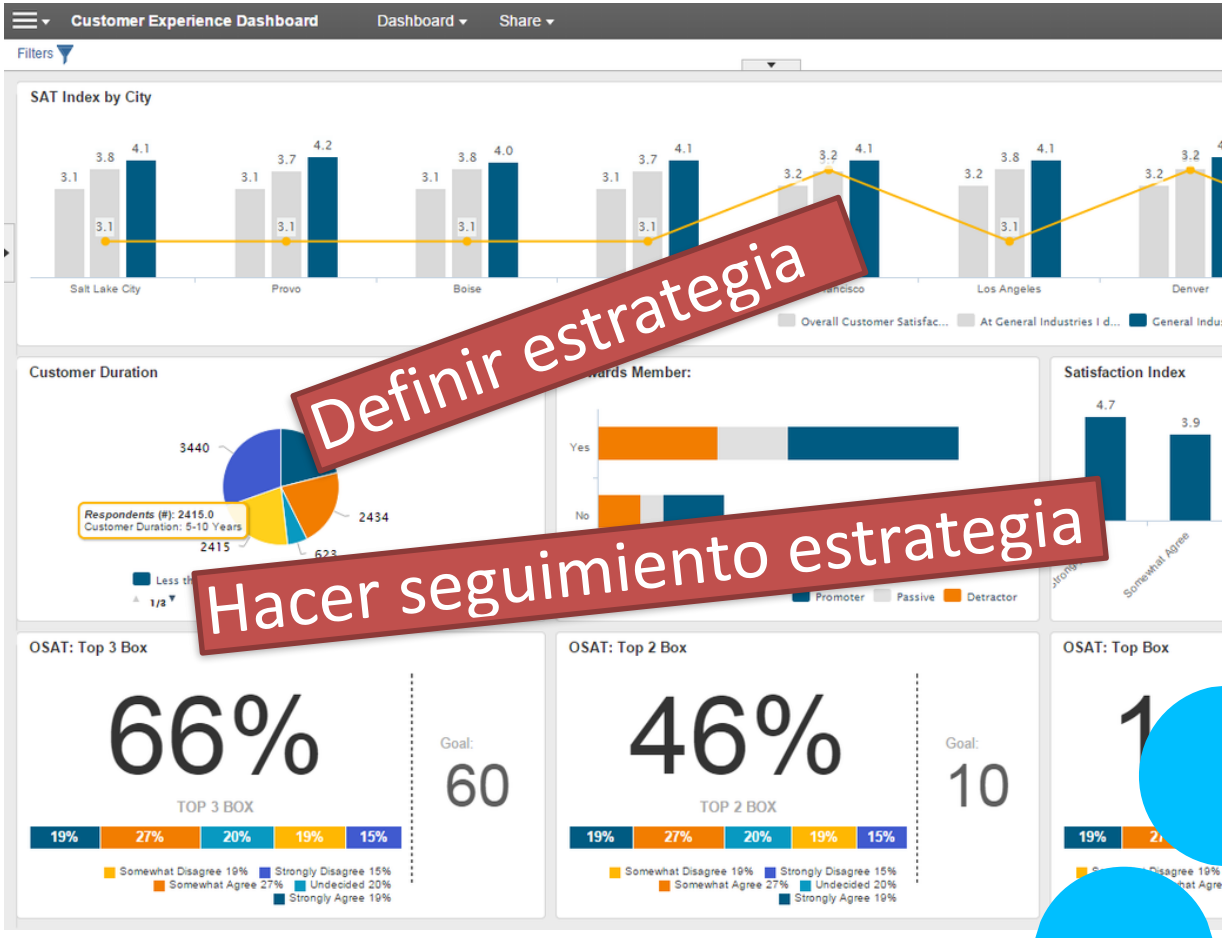

Visualización

Cuadro de mando

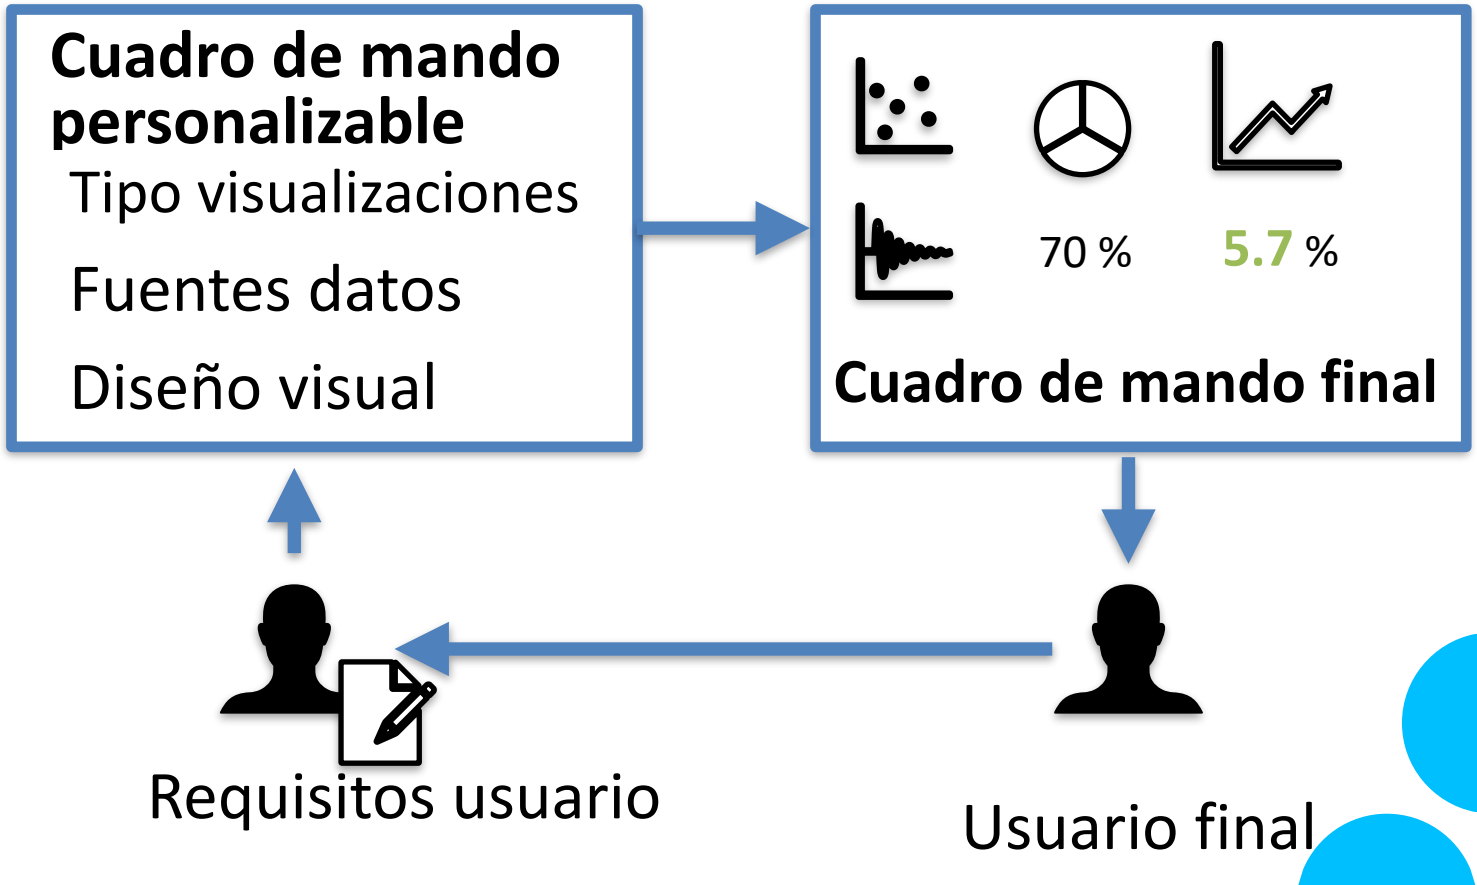

Visualización

- ¿Qué es?
- ¿Para qué?
- Características BD
- Cuadro de mando

Sistemas de Big Data

Ricardo García Ródenas
Ricardo.Garcia@uclm.es

Sistemas de
Big_Data

Curso Especialización
Inteligencia_Artificial y
Big_Data

Tipo	Modelo de datos	Técnica
Basada en registros	•Jerárquico: Los datos se almacenan en registros. Los registros tienen estructura de árbol donde cada registro tiene un único *padre* (nodo superior) • Red: Elaborado sobre un modelo jeráquico pero permitiendo que los registros tengan múltiples padres • Registros: Se especifica la estructura de toda la base de datos, definiendo los tipos de registros. Tienen un número determinado de campos con una longitud fijada. • Multidimensional: la estructura de datos contenida en la base de datos está mezclada con los propios datos. Es útil para fuentes de datos basadas en la web y para relacionar bases de datos de diferentes tipos.	ERD, Dic
Relacional	• Relacional: los datos están segmentados con la ayuda de tablas. Se emplea *Structured Query Language* (SQL) como su lenguaje canónico de base de datos. • Modelo de entidades-relación: describe la relación entre cosas de interés en un dominio de conocimiento. Un modelo básico ER está compuesto por tipo de entidades y especifica las relaciones que pueden existir entre estas entidades. • Modelo de datos relacional extendido (ERDM) es un híbrido del modelo relacional añadiendo funcionalidades de modelos orientados a objetos.	ERD, Dic
Basado en objetos	• Modelos orientados a objetos: consiste de objetos que poseen sus características y métodos. Estos modelos se pueden considerar que son post relacionales debido a que no se limitan a tablas aunque las empleen. • Modelo dato por contexto: este modelo incorpora varios modelos de datos según se necesitan, como relacional, orientado a objetos, semi estructurado entre otros. Este modelo permite varios tipos de usuarios que se diferencia en el modo de interactuar con la base de datos	UML ER
NoSQL	• Modelo de grafo. Se emplea una estructura de grafo con nodos, aristas y propiedades para representar los datos almacenados. • Modelo dato multievaludado: Este modelo permite respecto al modelo relacional que cada atributo en lugar de contener un dato unitario almacene una lista de datos. • Modelo de datos documento: este tipo permite almacenar y gestionar documento o dato semi-estructurados mas que datos atómicos.	Diccionar

Tabla 1.4: Taxonomía de modelos de datos